

Tarea 2 | Regresión | Estadística 3


13/05/2025





Sebastián Moreno Vargas

Objetivo: Aplicar los conceptos de KNN, regresión y GBM en datos reales. Entrega: Crear una rama utilizando el mismo repositorio de la tarea 1, crear otra carpeta llamada tarea 2, solucionar el problema y crear un pull request sobre la master donde me debe poner como reviewer (entregas diferentes tienen una reducción de 0.5 puntos). Se puede utilizar chat GPT. No se puede copiar la salida de chatGPT y pegarla.


1. Regresión

1.1 Realizar la exploración de los datos correlación, scatter plots, boxplots e histogramas








ESTU_TITULOBTENIDOBACHILLER vs PUNT_GLOBAL




ESTU_PAGOMATRICULABECA vs PUNT_GLOBAL







FAMI_TIENEHORNOMICROOGAS vs PUNT_GLOBAL



FAMI_TIENEAUTOMOVIL vs PUNT_GLOBAL





1.1.1 ¿Qué variables son importantes para predecir el valor?

Inicialmente se seleccionaron variables como:

- ESTU_INSE_INDIVIDUAL
- ESTU_NSE_INDIVIDUAL
- ESTU_NSE_IES
- ESTU_FECHANACIMIENTO
- ESTU_GENERO
- ESTU_EXTERIOR
- ESTU_AREARESIDE
- ESTU_PAGOMATRICULABECA
- FAMI_TIENEINTERNET
- FAMI_TIENEAUTOMOVIL
- ESTU_METODO_PRGM

Entre otras.

1.1.2 Existen nulos?, ¿cómo se deben imputar?

El set de datos contiene varios valores nulos, estos se deben imputar según el tipo de variable: si la variable es numérica, se utiliza la media; si es categórica, se utiliza la moda (o se coloca en 0 o 1 si la columna tiene demasiados nulos).

1.1.3 Crear una correlación, que variables tienen un efecto positivo en el puntaje y cuales un efecto negativo.

INST_CARACTER_ACADEMICO_UNIVERSIDAD	0.292784
ESTU_NSE_IES	0.262818
ESTU_VALORMATRICULAUNIVERSIDAD_Más de 7 millones	0.244534
ESTU_INSE_INDIVIDUAL	0.238292
ESTU_NSE_INDIVIDUAL	0.215721
...	
ESTU_VLRULTIMOSEMESCURSADO_Entre un millon y 3 millones de pesose	-0.185439
INST_COD_INSTITUCION	-0.205356
INST_CARACTER_ACADEMICO_INSTITUCIÓN UNIVERSITARIA	-0.223687
ESTU_FECHANACIMIENTO	-0.252675

La variables que a tienen un efecto positivo son principalmente el caracter académico de la universidad, el NSE, el valor de la matrícula, entre otras. La que tienen un efecto negativo son la edad, el caracter académico, el valor del semestre, entre otras.

1.2. Divida los datos en training y testing

1.2.3 ¿Cuál es el mejor R squared?Cuál es el MAPE y el MSE.

$$R^2=0.269$$

$$MAPE=\alpha$$

$$MSE=401.423$$

1.2.4 Utilizando los datos de test medir el MAPE y el MSE de test. Qué tan diferentes son las métricas de training.

$$R^2=0.274$$

$$MAPE=\alpha$$

$$MSE=401.516$$

La métricas de testing no son muy distintas a las de training.

1.2.5. Describa en palabras que dice el modelo cuales son los principales hallazgos.

El principal hallazgo es que el las variables seleccionadas no son buenas para explicar la variabilidad del puntaje global, ya que se obtuvo un valor un poco bajo.

2. Crear un modelo de KNN

2.1 Hacer pruebas con 5, 10, 20 y 30 vecinos. Seleccione el numero de vecinos basado en el error de test MSE.

Vecinos	MSE (train)	MSE (test)	MAPE (train)	MAPE (test)
5	318.58	480.47	∞	∞
10	359.48	442.96	∞	∞
20	383.01	426.02	∞	∞
30	391.51	420.28	∞	∞

Se seleccionaron 100 vecinos, ya que el error de test baja con cada vez más vecinos.

Vecinos	MSE	MAPE
100	318.58418.964	∞

Se evidencia que la regresión resulta ser más efectiva en todos los casos de prueba.

3. Crear un modelo de GBM

	MSE	MAPE
Train	618.12	∞
Test	618.48	∞

4. Crear un modelo de regresión logística

Entrenar una regresión logística, ¿cuales son las variables más importantes?

La importancia se determinó según los coeficientes para cada variable.

	Variable	Coeficiente
111	INST_CARACTER_ACADEMICO_UNIVERSIDAD	0.201224
3	ESTU_AREARESIDE	0.186003
14	FAMI_TIENEHORNOMICROOGAS	0.175395
22	ESTU_INSE_INDIVIDUAL	0.172372
116	INST_ORIGEN_OFICIAL NACIONAL	0.163433
...	...	...
17	FAMI_TIENEMOTOCICLETA	-0.194038
0	ESTU_GENERO	-0.195658
84	FAMI_ESTRATOVIVIENDA_Estrato 1	-0.215724
112	INST_ORIGEN_NO OFICIAL - CORPORACIÓN	-0.225327
1	ESTU_FECHANACIMIENTO	-0.476529

Crear una matriz de confusión, cual es la precisión, cuál es el recall, y el accuracy.

	No sobresaliente (Predicción)	Sobresaliente (Predicción)
No sobresaliente (Real)	77467	1259
Sobresaliente (Real)	8379	2039

Train

PRECISION = 0.618

ACCURACY = 0.891

RECALL = 0.195

Test

PRECISION = 0.605

ACCURACY = 0.888

RECALL = 0.190